МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
федеральное государственное бюджетное образовательное учреждение высшего образования
«УЛЬЯНОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»
Кафедра «Измерительно-вычислительные комплексы»

«Методы искусственного интеллекта»

Отчёт по лабораторной работе №3

Вариант №2

Выполнил:
студент группы ИСТбд-42
Апрелев Андрей
Проверил:
доцент кафедры ИВК, к.т.н.
Шишкин В.В.

Ульяновск
2022

Задание 1.
“Генерация данных”.

Создать симулированный набор данных и записать его на диск в виде csv файла со следующими параметрами:
- количество строк не менее 1000 (задается случайным образом);
- структура набора:
    - табельный номер;
    - Фамилия И.О.;
    - пол;
    - год рождения;
    - год начала работы в компании;
    - подразделение;
    - должность;
    - оклад;
    - количество выполненных проектов

Результат.

```
Generation process

number , full_name , gender , birth_date , start_date , division , position , salary , completed_projects ,
1 , Маврина Р.К. , Жен , 2.1.1995 , 6.12.2013 , Отдел поддержки ИТ , Специалист , 26924 , 38 ,
2 , Райкин С.К. , Муж , 8.9.1987 , 19.12.2016 , Отдел контроля качества и процесов , Специалист , 100506 , 24 ,
3 , Щукин Г.К. , Муж , 26.12.1994 , 20.6.2022 , Отдел разработки ПО , Middle разработчик , 68244 , 7 ,
4 , Павлов Ж.Б. , Муж , 27.10.1994 , 9.8.2014 , Отдел поддержки ИТ , Специалист , 27356 , 18 ,
5 , Павлова У.З. , Жен , 8.5.1990 , 10.1.2016 , Отдел развития ИТ , Руководитель отдела развития ИТ , 76308 , 51 ,
6 , Кабаков Г.М. , Муж , 14.12.1993 , 26.1.2012 , Отдел разработки ПО , Middle разработчик , 50172 , 2 ,
7 , Данилина Г.И. , Жен , 27.11.1986 , 9.8.2013 , Отдел информационной безопасности , Начинающий специалист , 55460 , 17 ,
8 , Хабалова Э.Л. , Жен , 17.9.1996 , 9.11.2017 , Отдел поддержки ИТ , Специалист , 28422 , 22 ,
9 , Царёв Б.К. , Муж , 2.12.1989 , 25.2.2012 , Отдел поддержки ИТ , Руководитель отдела поддержки ИТ , 32868 , 45 ,
```

Задание 2.
“Получение статистических характеристик при помощи библиотеки numpy”.

Прочитать сгенерированный набор данных в виде списков и получить с помощью программирования и методов библиотеки numpy для разных по типу признаков столбцов (не менее 3) основные статистические характеристики (например для порядкового типа: минимум, максимум, среднее, дисперсия, стандартное отклонение, медиана, мода).

Результат.

```
Statistical characteristics

For column number: min=1 ; max=1999 ; ave=1000.0 ; disp=333000.0 ; std=577.0615218501404 ; median=1000.0 ; mode=1
For column salary: min=10047 ; max=299190 ; ave=89180.19009504752 ; disp=4033217756.9813724 ; std=63507.61967655041 ; median=71600.0 ; mode=30472
For column projects: min=1 ; max=60 ; ave=21.15057528764382 ; disp=235.83875779810867 ; std=15.35704261236872 ; median=18.0 ; mode=18

CSV file analyzed (Press Enter)
```

Задание 3.
“Получение статистических характеристик при помощи библиотеки pandas”.

Прочитать сгенерированный набор данных в виде датафрейма и получить с помощью методов библиотеки pandas для тех же столбцов те же статистические характеристики. Продемонстрировать применение не менее 3 методов библиотеки pandas.

Результат.

```
Statistical characteristics

For column number: min=1 ; max=1999 ; ave=1000.0 ; disp=333166.6666666667 ; std=577.2059135756205 ; median=1000.0 ; mode=1
For column salary: min=10047 ; max=299190 ; ave=89180.19009504752 ; disp=4035236384.487369 ; std=63523.51048617645 ; median=71600.0 ; mode=30472
For column projects: min=1 ; max=60 ; ave=21.15057528764382 ; disp=235.95679521442403 ; std=15.36088523537703 ; median=18.0 ; mode=18

CSV file analyzed (Press Enter)
```

Задание 4.
“Построение графиков”.

Построить не менее 3 разнотипных графиков.

Результат.

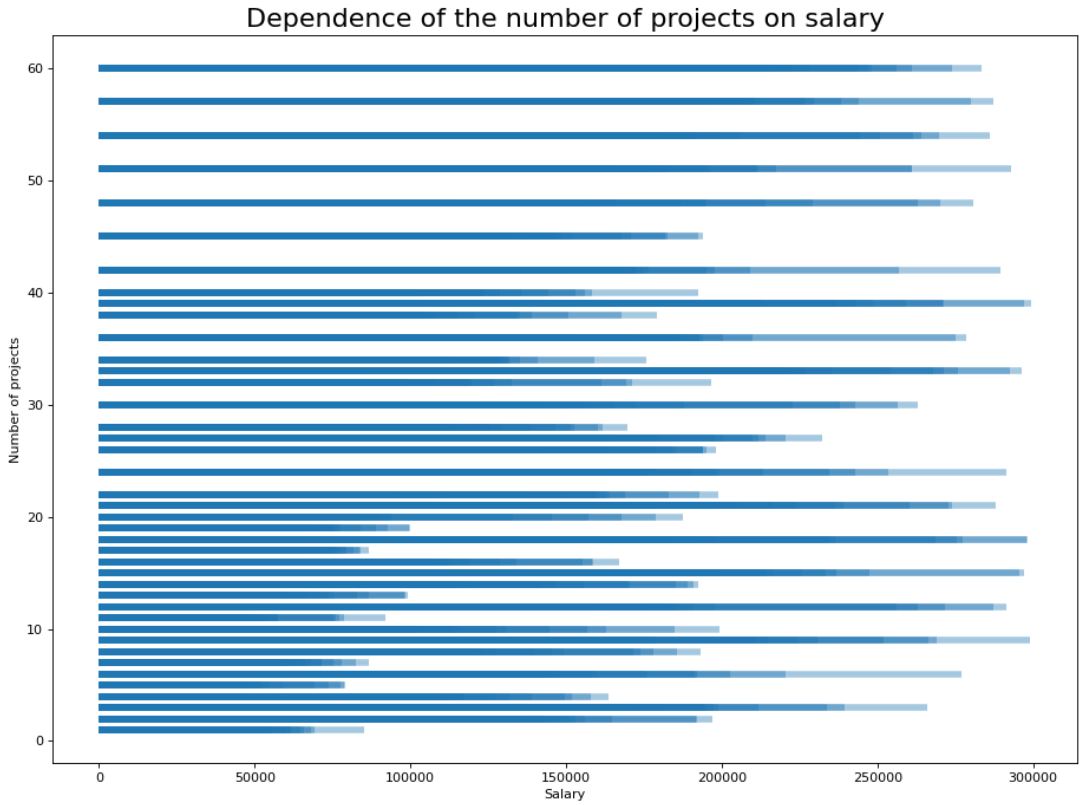

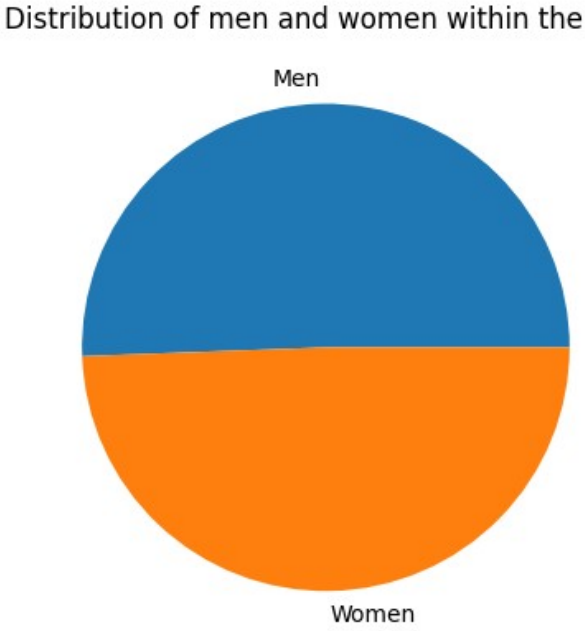
Distribution of men and women within the firm
Men
Women

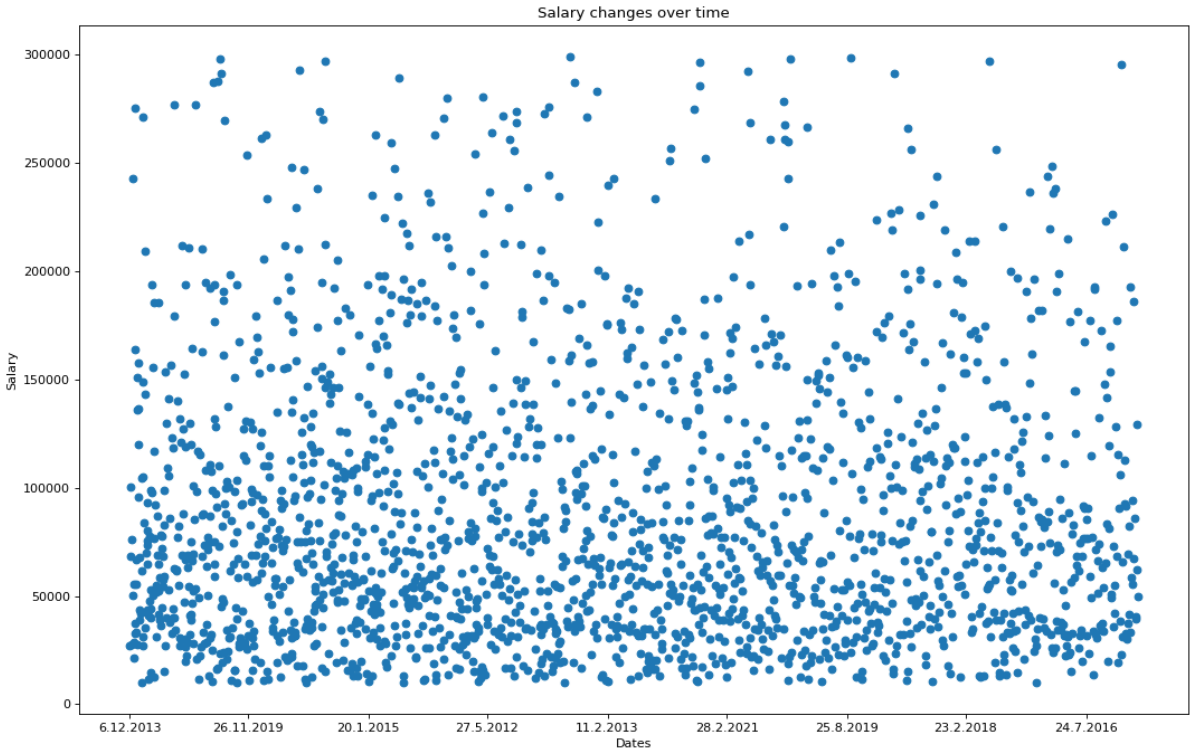
Salary changes over time
Salary
300000
250000
200000
150000
100000
50000
0
6.12.2013
26.11.2019
20.1.2015
27.5.2012
11.2.2013
28.2.2021
25.8.2019
23.2.2018
24.7.2016
Dates

Задание 5.
“Оценка библиотек numpy и pandas”.

Оценить возможности библиотек csv, numpy, pandas в форме отчета по лабораторной работе.

Результат.

Numpy
Numpy (Numerical Python) - библиотека, реализующая инструменты для обработки больших одномерных и многомерных массивов и матриц. Содержит в себе большое количество высокоуровневых функций для операций с этими массивами. Скорость выполнения математических функций Numpy зачастую превышает скорость аналогичных алгоритмов, реализованных вне этой библиотеки.

CSV
CSV (Comma-Separated Value) - формат представления тфбличных данных, где каждая строка файла - строка таблицы, разделитель может быть любым. Бибилиотека CSV позволяет работать с файлами в CSV формате. Данные можно прочитать из файла, записать в файл.

Pandas
Pandas (Panel Data) - библиотека для обработки и анализа структурированных данных. Позволяет использовать объект DataFrame для манипулирования двумерными массивами данных, предоставляет средства совмещения данных и обработки отсутствующей информации, а также для обмена данными между файлами различными форматов и структурами в памяти.

Код.

```
import csv
import numpy as np
from numpy.random import choice
from numpy import genfromtxt
import datetime as dt
import os
import pandas as ps
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import matplotlib.dates as mdates

def graph():

    MyDataFrame = ps.read_csv('data.csv')
    numbers = MyDataFrame["number"]
```

```
    num_min = numbers.min()
    num_max = numbers.max()
    num_ave = numbers.mean()
    num_disp = numbers.var()
    num_std = numbers.std()
    num_median = numbers.median()
    num_mode = mode(numbers)
    salary = MyDataFrame["salary"]
    sal_min = salary.min()
    sal_max = salary.max()
    sal_ave = salary.mean()
    sal_disp = salary.var()
    sal_std = salary.std()
    sal_median = salary.median()
    sal_mode = mode(salary)
    projects = MyDataFrame["completed_projects"]
    pjt_min = projects.min()
    pjt_max = projects.max()
    pjt_ave = projects.mean()
    pjt_disp = projects.var()
    pjt_std = projects.std()
    pjt_median = projects.median()
    pjt_mode = mode(projects)

    plt.figure(figsize=(14, 10), dpi=80)
    plt.hlines(y=projects, xmin=0, xmax=salary, color='C0', alpha=0.4, linewidth=5)
    plt.gca().set(ylabel='Number of projects', xlabel='Salary')
    plt.title('Dependence of the number of projects on salary', fontdict={'size': 20})
    plt.show()

    data=[MyDataFrame["gender"].value_counts()
["Муж"],MyDataFrame["gender"].value_counts()["Жен"]]
    plt.pie(data, labels=["Men","Women"])
    plt.title("Distribution of men and women within the firm")
    plt.ylabel("")
    plt.show()

    data=MyDataFrame
    myLocator = mticker.MultipleLocator(4)
    plt.figure(figsize=(16, 10), dpi=80)
    plt.plot_date(data["start_date"],data["salary"])
    plt.gca().xaxis.set_major_locator(mdates.AutoDateLocator())
    plt.ylabel('Salary')
    plt.xlabel('Dates')
    plt.title("Salary changes over time")
    plt.show()

def mode(values):

    dict={}
    for elem in values:
        if elem in dict:
            dict[elem]+=1
        else:
            dict[elem]=1
    v = list(dict.values())
    k = list(dict.keys())

    return k[v.index(max(v))]

def generate():
```

```
    MyData = [["number", "full_name", "gender", "birth_date", "start_date", "division",
"position", "salary",
              "completed_projects"]]
    Gender = ["Муж", "Жен"]
    Surnames = ["Антипов", "Бабаев", "Вавилов", "Галкин", "Данилин", "Евсюткин",
"Жеглов", "Задорнов", "Ивачев",
                "Кабаков", "Лабутин",
                "Маврин", "Назаров", "Овсеев", "Павлов", "Райкин", "Савочкин", "Табаков",
"Уваров", "Фандеев",
                "Хабалов", "Царёв", "Чадов",
                "Шаляпин", "Щукин", "Эвентов", "Юров", "Ягодин"]
    Initials = ["А", "Б", "В", "Г", "Д", "Ж", "З", "И", "К", "Л", "М", "Н", "Р", "С", "Т", "У", "Ф",
"Э", "Ю", "Я"]
    Divisions = ["Отдел информационной безопасности", "Отдел разработки ПО", "Отдел
контроля качества и процесов",
                 "Отдел развития ИТ", "Отдел поддержки ИТ"]
    Positions = [["Руководитель отдела информационной безопасности", "Специалист",
"Начинающий специалист"],
                 ["Руководитель отдела разработки ПО", "Senior разработчик", "Middle
разработчик"],
                 ["Руководитель отдела контроля качества и процесов", "Специалист",
"Работник"],
                 ["Руководитель отдела развития ИТ", "Специалист", "Работник"],
                 ["Руководитель отдела поддержки ИТ", "Специалист", "Работник"]]

    for i in range(1, 2000):
        np.random.seed(i)
        num = i
        full_name = ""
        gend = ""
        birth = ""
        start = ""
        div = ""
        pos = ""
        salary = 0
        completed_projects = 0

        gender = np.random.randint(0, 2)
        gend = Gender[gender]
        if (gender != 0):
            full_name = Surnames[np.random.randint(0, 27)] + "а " +
Initials[np.random.randint(0, 19)] + "." + Initials[
                np.random.randint(0, 19)] + "."
        else:
            full_name = Surnames[np.random.randint(0, 27)] + " " +
Initials[np.random.randint(0, 19)] + "." + Initials[
                np.random.randint(0, 19)] + "."
        current_date = dt.date.today()
        year = current_date.year - np.random.randint(0, 11)
        month = np.random.randint(1, 13)
        day = np.random.randint(1, 29)
        start = str(day) + "." + str(month) + "." + str(year)
        byear = year - np.random.randint(18, 31)
        bmonth = np.random.randint(1, 13)
        bday = np.random.randint(1, 29)
        birth = str(bday) + "." + str(bmonth) + "." + str(byear)
        divis = np.random.randint(0, 5)
        div = Divisions[divis]
        posit = choice([0, 1, 2], 1, [0.1, 0.3, 0.6])[0]
        pos = Positions[divis][posit]
        salary = np.random.randint(10000, 20001) * (5 - divis) * (3 - posit)
        completed_projects = np.random.randint(1, 21) * (3 - posit)
```

```
        MyData.append([num, full_name, gend, birth, start, div, pos, salary,
completed_projects])

    for per in MyData:
        for param in per:
            print(param, end=" , ")
        print("")

    with open("data.csv", mode="w", encoding='utf-8') as w_file:
        file_writer = csv.writer(w_file, delimiter=",", lineterminator="\r")
        for per in MyData:
            file_writer.writerow(per)

def np_stat():

    MyData = []

    with open('data.csv', mode="r", encoding='utf-8') as f:
        reader = csv.reader(f)
        for row in reader:
            data=row

MyData.append([data[0],data[1],data[2],data[3],data[4],data[5],data[6],data[7],data[8]])

    for per in MyData:
        for param in per:
            print(param, end=" , ")
        print("")

    MyData=np.array(MyData)
    numbers=np.array(MyData[:,0])
    numbers=np.delete(numbers, 0)
    numbers=[int(item) for item in numbers]
    num_min=np.min(numbers)
    num_max=np.max(numbers)
    num_ave= np.average(numbers)
    num_disp=np.var(numbers)
    num_std=np.std(numbers)
    num_median=np.median(numbers)
    num_mode=mode(numbers)
    salary=np.array(MyData[:,7])
    salary=np.delete(salary,0)
    salary = [int(item) for item in salary]
    sal_min=np.min(salary)
    sal_max=np.max(salary)
    sal_ave=np.average(salary)
    sal_disp=np.var(salary)
    sal_std=np.std(salary)
    sal_median = np.median(salary)
    sal_mode=mode(salary)
    projects=np.array(MyData[:,8])
    projects = np.delete(projects, 0)
    projects = [int(item) for item in projects]
    pjt_min = np.min(projects)
    pjt_max = np.max(projects)
    pjt_ave = np.average(projects)
    pjt_disp = np.var(projects)
    pjt_std = np.std(projects)
    pjt_median = np.median(projects)
    pjt_mode=mode(projects)
    print(numbers)
```

```
    print("")
    print("Statistical characteristics")
    print("")
    print("For column number: min="+str(num_min)+" ; max="+str(num_max)+" ;
ave="+str(num_ave)+" ; disp="+str(num_disp)+" ; std="+str(num_std)+" ;
median="+str(num_median)+" ; mode="+str(num_mode))
    print("For column salary: min=" + str(sal_min) + " ; max=" + str(sal_max) + " ; ave=" +
str(sal_ave) + " ; disp=" + str(sal_disp) + " ; std=" + str(sal_std) + " ; median=" +
str(sal_median) + " ; mode=" + str(sal_mode))
    print("For column projects: min=" + str(pjt_min) + " ; max=" + str(pjt_max) + " ; ave=" +
str(pjt_ave) + " ; disp=" + str(pjt_disp) + " ; std=" + str(pjt_std) + " ; median=" +
str(pjt_median) + " ; mode=" + str(pjt_mode))

def ps_stat():

    MyDataFrame = ps.read_csv('data.csv')
    numbers=MyDataFrame["number"]
    num_min = numbers.min()
    num_max = numbers.max()
    num_ave = numbers.mean()
    num_disp = numbers.var()
    num_std = numbers.std()
    num_median = numbers.median()
    num_mode = mode(numbers)
    salary = MyDataFrame["salary"]
    sal_min = salary.min()
    sal_max = salary.max()
    sal_ave = salary.mean()
    sal_disp = salary.var()
    sal_std = salary.std()
    sal_median = salary.median()
    sal_mode = mode(salary)
    projects = MyDataFrame["completed_projects"]
    pjt_min = projects.min()
    pjt_max = projects.max()
    pjt_ave = projects.mean()
    pjt_disp = projects.var()
    pjt_std = projects.std()
    pjt_median = projects.median()
    pjt_mode = mode(projects)
    print(MyDataFrame.to_string())

    print("")
    print("Statistical characteristics")
    print("")
    print("For column number: min=" + str(num_min) + " ; max=" + str(num_max) + " ;
ave=" + str(num_ave) + " ; disp=" + str(num_disp) + " ; std=" + str(num_std) + " ;
median=" + str(num_median) + " ; mode=" + str(num_mode))
    print("For column salary: min=" + str(sal_min) + " ; max=" + str(sal_max) + " ; ave=" +
str(sal_ave) + " ; disp=" + str(sal_disp) + " ; std=" + str(sal_std) + " ; median=" +
str(sal_median) + " ; mode=" + str(sal_mode))
    print("For column projects: min=" + str(pjt_min) + " ; max=" + str(pjt_max) + " ; ave=" +
str(pjt_ave) + " ; disp=" + str(pjt_disp) + " ; std=" + str(pjt_std) + " ; median=" +
str(pjt_median) + " ; mode=" + str(pjt_mode))

if __name__ == '__main__':

    print("Generation process")
    print("")

    generate()
```

```
print("")
print("CSV file created (Press Enter)")
input()

print("Numpy statistics")
print("")

np_stat()

print("")
print("CSV file analyzed (Press Enter)")
input()

print("Pandas statistics")
print("")

ps_stat()

print("")
print("CSV file analyzed (Press Enter)")
input()

print("Graphics")
print("")

graph()

print("")
print("CSV file removed")
os.remove("data.csv")
```